

Benchmarking Generative Models for Domain Adaptation

Progetto di Deep Learning

Anno Accademico 2025-2026

Marco Gionfriddo, Antonio Rosano, Angelo Spadola

Indice

1	Problema	1
2	Soluzione Proposta	4
2.1	Segmentazione Semantica	4
2.2	Domain Adaptation	4
2.2.1	CUT	5
2.2.2	UNIT	5
2.2.3	MUNIT	5
3	Dataset	6
3.1	EGO-CH	6
3.2	Sbilanciamento delle Classi	7
3.3	Metriche di Valutazione	7
3.4	Inconsistenze del Dataset	7
4	Esperimenti e Risultati	10
4.1	Pre-Training sul Dominio Sintetico	10
4.2	Domain Adaptation tramite Image-to-Image Translation . . .	13
4.2.1	Traduzione con CUT	13
4.2.2	Traduzione con UNIT	17
4.2.3	Traduzione con MUNIT	19
4.3	Fine-Tuning e Valutazione sul Dominio Target	23
4.3.1	Adattamento tramite CUT	23
4.3.2	Adattamento tramite UNIT	27
4.3.3	Adattamento tramite MUNIT	29
4.3.4	Confronto Quantitativo	33
5	Conclusioni	35

Capitolo 1

Problema

Introduzione

Negli ultimi anni, le tecniche di Computer Vision hanno aperto nuove frontiere per la valorizzazione del patrimonio culturale. Applicazioni come le guide museali interattive, la realtà aumentata e i sistemi di raccomandazione automatica richiedono che i dispositivi siano in grado di "comprendere" l'ambiente circostante. Alla base di questa comprensione visiva c'è la **segmentazione semantica**, ovvero la capacità di un modello di Intelligenza Artificiale di classificare ogni singolo pixel di un'immagine, distinguendo ad esempio un quadro da una sedia, o un elemento architettonico da un espositore.

L'addestramento di reti neurali profonde per la segmentazione richiede enormi quantità di dati etichettati. Si tratta di un processo estremamente costoso in termini di tempo e risorse umane: ogni immagine reale deve essere infatti mascherata manualmente pixel per pixel. Una soluzione moderna ed efficiente consiste nello sfruttare **dati sintetici**. Grazie alla modellazione 3D dei siti museali, è possibile generare infinite viste foto-realistiche degli ambienti, ottenendo automaticamente e a costo zero le relative maschere di segmentazione.

Nonostante i vantaggi, l'utilizzo esclusivo di dati sintetici introduce una criticità nota come **Domain Gap**. Un modello addestrato unicamente su immagini sintetiche (Dominio Sorgente) tende a generalizzare in modo subottimale quando viene testato su fotografie reali (Dominio Target). Il crollo delle prestazioni è dovuto alle differenze intrinseche tra i due domini: illuminazione, rumore del sensore, texture dei materiali e imperfezioni del mondo reale che il motore di rendering non riesce a replicare fedelmente. Il modello impara la geometria e la disposizione spaziale degli oggetti, ma viene "confuso" dallo

stile visivo delle fotografie reali.

Obiettivo del Lavoro

Il presente elaborato nasce con lo scopo primario di replicare, analizzare e validare metodologicamente il lavoro di ricerca presentato nell'articolo "*Semantic Object Segmentation in Cultural Sites using Real and Synthetic Data*" (Ragusa et al.), che costituisce il punto di riferimento e la base fondante di questo studio.

Nel paper originale, gli autori affrontano innanzitutto il problema della segmentazione semantica in ambienti museali caratterizzati dalla scarsità di dati reali etichettati. Per ovviare a questo limite, lo studio esplora l'uso massiccio di immagini sintetiche, scontrandosi però con il conseguente problema del *Domain Gap* tra il dominio sintetico e quello reale. Per mitigare tale discrepanza, gli autori mettono a confronto tre diversi approcci di addestramento per la rete PSPNet:

- **PSPNet_R**: l'addestramento esclusivo su dati reali, che funge da baseline per mostrare i limiti prestazionali dovuti alla scarsità di annotazioni;
- **PSPNet_S+R**: un pre-addestramento su dati sintetici seguito da una fase di fine-tuning su un sottoinsieme limitato di immagini reali;
- **PSPNet_S+R+CycleGAN**: un approccio ibrido in cui la rete, pre-addestrata sui dati sintetici, subisce un fine-tuning su immagini reali tradotte nel dominio sintetico tramite tecniche di image-to-image translation.

Nello specifico, lo studio di riferimento impiegava l'architettura **CycleGAN** per la traduzione stilistica delle immagini, dimostrando che l'aggiunta dei dati tradotti migliora sensibilmente le prestazioni della rete di segmentazione, riducendo al contempo la dipendenza da grandi quantità di dati reali annotati manualmente.

Seguendo le orme e la pipeline tracciata da tale ricerca, questo progetto si pone come obiettivo la riproduzione dell'esperimento, in particolare del terzo approccio, partendo dallo stesso dataset di riferimento (EGO-CH) e sostituendo l'architettura CycleGAN utilizzata nello studio originale con una serie di modelli generativi quali:

1. **CUT** (Contrastive Unpaired Translation);
2. **UNIT** (Unsupervised Image-to-Image Translation);

3. MUNIT (Multimodal Unsupervised Image-to-Image Translation).

Dopo aver effettuato il *fine-tuning* della rete di segmentazione **PSPNet** sulle nuove immagini generate, vengono analizzati i risultati quantitativi (tramite metriche come la *Mean IoU* e la *Pixel Accuracy*) e qualitativi, permettendo di costruire un benchmark tra i modelli generativi testati. Viene posta particolare attenzione alla capacità dei vari modelli di gestire lo sbilanciamento delle classi in un contesto dove lo sfondo architettonico risulta fortemente predominante rispetto ai singoli artefatti di interesse.

Capitolo 2

Soluzione Proposta

Questo capitolo fornisce le basi teoriche necessarie per comprendere le architetture impiegate nel progetto. Verrà prima descritta la rete utilizzata per il task di segmentazione semantica, per poi analizzare singolarmente i modelli generativi adottati per affrontare il problema della domain adaptation.

2.1 Segmentazione Semantica

L'obiettivo di un algoritmo di segmentazione semantica è quello di assegnare un'etichetta di classe a ciascun pixel di una determinata immagine di input. Nel corso degli anni, sono stati proposti diversi approcci basati su reti neurali convoluzionali (CNN) addestrate in modo supervisionato per effettuare questa classificazione pixel per pixel. Nello studio di riferimento di questo progetto, gli autori hanno selezionato PSPNet (Pyramid Scene Parsing Network) come baseline allo stato dell'arte per condurre gli esperimenti di segmentazione. L'architettura di PSPNet si distingue per la sua capacità di catturare il contesto globale dell'immagine, un elemento fondamentale per evitare errori di classificazione dovuti a feature puramente locali. Il cuore di questa rete è il modulo di *Pyramid Pooling*, progettato per migliorare spazialmente le feature a livello di pixel sfruttando il pooling globale a diverse scale.

2.2 Domain Adaptation

Lo scopo delle tecniche di domain adaptation è ridurre il calo di prestazioni causato dal domain shift tra la distribuzione dei dati di addestramento e quelli di test. Tale disallineamento è molto comune quando le immagini provengono da contesti di acquisizione differenti, come nel caso di dati sintetici generati

al computer e fotografie reali. Un approccio consolidato per ridurre il domain shift consiste nell'impiego di tecniche di *image-to-image translation* basate su GAN. Nello studio di riferimento, gli autori hanno selezionato CycleGAN. Il presente progetto esplora l'evoluzione della ricerca: il nostro lavoro sostituisce infatti CycleGAN con architetture generative differenti come: CUT, UNIT e MUNIT. L'obiettivo è quello di valutare se questi modelli possano ottimizzare l'efficienza computazionale e migliorare la qualità della traduzione ai fini della domain adaptation.

2.2.1 CUT

A differenza di CycleGAN, che si affida a due generatori e due discriminatori per imporre una *cycle-consistency* (ovvero la capacità di tornare all'immagine originale dopo una doppia traduzione), CUT sfrutta i principi del *Contrastive Learning*. L'idea centrale di CUT si basa sul concetto secondo cui, anziché valutare solo l'immagine nel suo complesso, il modello analizza e confronta piccoli "tasselli" (patch) dell'immagine. Il suo obiettivo è fare in modo che un tassello dell'immagine originale sia strettamente legato, dal punto di vista del contenuto, allo stesso identico tassello nell'immagine tradotta. Il grande vantaggio architetturale è che, grazie a questo meccanismo, CUT riesce a preservare la struttura dell'immagine utilizzando un solo generatore e un solo discriminatore. Evitando la complessa "doppia traduzione" richiesta da modelli come CycleGAN, CUT riduce drasticamente il carico di lavoro per il computer e i tempi di addestramento.

2.2.2 UNIT

Si basa sull'ipotesi dello spazio latente condiviso. UNIT assume che immagini appartenenti a domini diversi, ma raffiguranti la stessa scena (es. una statua reale e il suo corrispettivo sintetico 3D), possano essere mappate in una singola rappresentazione astratta condivisa in uno spazio latente.

2.2.3 MUNIT

Estende i concetti di UNIT scomponendo lo spazio latente in due componenti distinte: uno spazio del contenuto (condiviso tra i domini, che codifica la geometria e la struttura dell'opera) e uno spazio dello stile (specifico per ogni dominio, che codifica texture e illuminazione). Questo approccio multimodale consente una maggiore flessibilità nel controllo della traslazione stilistica.

Capitolo 3

Dataset

Questo capitolo descrive i dati utilizzati per l'addestramento, illustrando le caratteristiche del dataset di riferimento. Vengono inoltre definite le metriche impiegate per la valutazione quantitativa degli esperimenti di segmentazione semantica.

3.1 EGO-CH

Per condurre l'analisi comparativa, il progetto sfrutta il dataset EGO-CH, specificamente raccolto all'interno della Galleria Regionale di Palazzo Bello-mo a Siracusa. Il dataset comprende immagini accoppiate (reali e sintetiche) di 24 specifiche opere d'arte, annotate a livello di singolo pixel.

Le immagini reali sono state acquisite dal punto di vista dei visitatori tramite dispositivi indossabili. Gli autori dello studio di riferimento hanno etichettato manualmente 5588 immagini con maschere di segmentazione semantica. Di queste, 4740 sono destinate al training, 170 alla validazione e 678 al test.

Per superare i limiti quantitativi dei dati reali, è stato generato un vasto corpus di immagini sintetiche a partire da un modello 3D del sito culturale. Utilizzando un tool automatizzato basato su Blender, sono state prodotte 24.000 immagini sintetiche complessive (di cui 12.000 per l'addestramento, 1.200 per la validazione e 10.800 per il test), ovvero 1.000 immagini per ciascuna delle 24 opere da molteplici punti di vista, complete delle relative maschere di segmentazione.

3.2 Sbilanciamento delle Classi

Una delle sfide principali affrontate in questo progetto riguarda lo sbilanciamento intrinseco dei dati. Nelle immagini egocentriche acquisite in un ambiente museale, le opere d'arte occupano solitamente solo una piccola porzione dell'inquadratura, mentre la stragrande maggioranza dei pixel appartiene alla classe di background (pareti, pavimenti, espositori e altri elementi architettonici). Questo forte squilibrio richiede particolare attenzione durante le fasi di addestramento e valutazione, poiché un modello potrebbe ottenere un'accuratezza globale apparentemente elevata limitandosi a classificare correttamente il solo sfondo, fallendo però nel compito cruciale di segmentare i singoli artefatti.

3.3 Metriche di Valutazione

Per valutare in modo rigoroso le prestazioni della rete PSPNet a seguito del fine-tuning sulle immagini tradotte, vengono impiegate le metriche standard per i task di segmentazione semantica:

- **Accuracy (Global Accuracy):** Calcola la percentuale complessiva di pixel classificati correttamente in tutta l'immagine. Sebbene utile come indicatore generale, risulta sensibile allo sbilanciamento delle classi.
- **Class Accuracy:** Calcola l'accuratezza in modo indipendente per ciascuna classe, restituendone poi la media. Questa metrica mitiga l'effetto dominante del background.
- **Mean IoU (Intersection over Union):** È la metrica più rappresentativa per valutare la precisione dei confini degli oggetti. Misura il grado di sovrapposizione tra la maschera predetta dal modello e la maschera di ground truth, mediando poi il risultato su tutte le classi.
- **FWAVACC (Frequency Weighted Average Jaccard Index):** Simile alla Mean IoU, ma i valori di IoU per classe vengono aggregati utilizzando una media ponderata basata sul numero effettivo di pixel presenti in ciascuna classe.

3.4 Inconsistenze del Dataset

Durante la fase di esplorazione e pre-elaborazione dei dati forniti, è emersa una forte criticità legata all'integrità del dataset sintetico, che impatta

direttamente sulle dinamiche di apprendimento supervisionato. Nello specifico, l'accoppiamento tra le immagini (frames) e le rispettive maschere di segmentazione (labels) ha rivelato due problematiche fondamentali:

- **Dati mancanti e disallineamento dei file:** Nelle directory del dataset (in particolare nella sezione delle immagini sintetiche), la corrispondenza biunivoca basata sulla nomenclatura dei file è risultata assente. Si sono riscontrati casi di immagini prive della relativa maschera e, viceversa, maschere orfane dell'immagine originale. Questo ha costretto a ridurre il dataset drasticamente da circa 12.000 immagini a poco meno di 6.000.
- **Incoerenza semantica e visiva:** Anche nei casi in cui l'accoppiamento tra i file risultava corretto a livello di nomenclatura, l'ispezione visiva ha evidenziato una grave mancanza di coerenza logica. Spesso, la maschera di segmentazione non ricalcava la geometria dell'oggetto presente nell'immagine corrispondente.

In un task di segmentazione semantica, la correttezza del ground truth è un requisito imprescindibile. La presenza di un "label noise" così marcato rappresenta un ostacolo severo per l'addestramento della rete PSPNet, poiché il calcolo della funzione di Loss si basa su associazioni spaziali errate, impedendo al modello di estrarre feature visive coerenti per le classi di interesse.



Figura 3.1: Inconsistenza del dataset.

Capitolo 4

Esperimenti e Risultati

Questo capitolo presenta l'analisi sperimentale condotta per valutare l'efficacia dei diversi approcci generativi nel mitigare il domain gap. Vengono illustrati i risultati delle fasi di addestramento, partendo dalla definizione della baseline sul dominio sintetico, per poi passare all'analisi qualitativa delle traduzioni tra domini e, infine, al confronto quantitativo sulle prestazioni di segmentazione a seguito del fine-tuning.

4.1 Pre-Training sul Dominio Sintetico

Al fine di stabilire un punto di partenza per valutare l'entità del domain shift, il primo esperimento consiste nel pre-addestramento della rete PSPNet esclusivamente sui dati sintetici.

Per l'estrazione delle feature, l'architettura PSPNet è stata inizializzata sfruttando i pesi della rete *ResNet50*. Per garantire la riproducibilità dell'esperimento sul dominio sorgente (composto da 25 classi semantiche), l'addestramento è stato configurato seguendo un setup basato sui seguenti iperparametri:

- Le immagini sono state elaborate con una risoluzione di 473×473 pixel. Per favorire la generalizzazione e consentire alla rete di inquadrare correttamente le opere d'arte nella loro interezza all'interno della scena, sono state applicate trasformazioni spaziali casuali, tra cui uno scaling variabile tra 0.5 e 2.0 e una rotazione compresa tra i -10 e i 10 gradi.
- È stato impostato un **batch size** pari a 4. L'ottimizzazione dei pesi è stata fatta con un **learning rate** iniziale di 0.005. Sono stati inoltre

applicati un **momentum** di 0.9 e un **weight decay** di 0.0001 per mitigare i fenomeni di sovradattamento.

Il modello è stato addestrato per 30 epoche complessive, monitorando l'andamento della funzione di Loss e delle metriche di valutazione per valutarne la convergenza (mAcc e mIoU).




Figura 4.1: Andamento della Loss di addestramento e validazione durante le 30 epoche di pre-training sul dominio sintetico.

Come si evince dall'andamento della Loss durante l'addestramento (Figura 4.1), il modello mostra una dinamica di apprendimento tipica di contesti affetti da Domain Shift. La Loss di training decresce in modo stabile e continuo (passando da circa 0.30 a meno di 0.10), confermando che la rete riesce a estrarre ed apprendere correttamente le feature geometriche dal dataset sintetico. Al contrario, la Loss di validazione si presenta estremamente instabile e rumorosa, evidenziando una forte divergenza nella seconda metà dell'addestramento (con picchi superiori a 0.60). Questo andamento suggerisce una scarsa capacità di generalizzazione e un marcato overfitting.




Figura 4.2: Confronto delle metriche Mean Class Accuracy e Mean IoU sul dominio sintetico.

Una volta ottenuto il modello pre-addestrato sul dominio sintetico, questo è stato testato per quantificare numericamente il divario visivo rispetto al dominio reale. Questo scenario (equivalente allo 0% di dati reali forniti alla rete per il fine-tuning) è fondamentale per stabilire la nostra baseline.

L'analisi delle metriche di accuratezza (Mean Class Accuracy) e Mean IoU conferma la gravità del domain shift. I grafici di addestramento (Figura 4.2) mostrano valori assoluti bassi fin dalle prime epoche. I risultati quantitativi finali ottenuti dal modello testato direttamente sulle immagini reali sono i seguenti:

- **Mean Class Accuracy:** $\approx 10.6\%$
- **Mean IoU:** $\approx 7.1\%$

L'analisi dei grafici di addestramento e dei risultati quantitativi (con una Mean IoU ferma al 7%) evidenzia un palese fallimento del modello nel task di segmentazione. Alla luce dell'analisi esplorativa condotta sui dati (Sezione 3.4), questo risultato non è imputabile a limiti architetturali di PSPNet, bensì alla grave inconsistenza del dataset sintetico utilizzato per il pre-training. Il modello è stato infatti addestrato su coppie immagine-maschera affette da un massiccio label noise. La rete, non trovando una correlazione visiva costante tra l'aspetto dell'opera d'arte e l'etichetta fornita dalla maschera incoerente, non è riuscita a convergere verso una rappresentazione semantica valida, limitandosi presumibilmente a classificare i pixel di background per abbassare la Loss globale. Questo difetto strutturale dei dati di partenza penalizza l'intera baseline e rende ancora più sfidante la successiva fase di domain adaptation.

4.2 Domain Adaptation tramite Image-to-Image Translation

Per mitigare il domain shift, si è proceduto con l'addestramento dei modelli generativi descritti precedentemente (CUT, UNIT e MUNIT). L'obiettivo di questa fase è imparare a tradurre le immagini appartenenti al dominio reale verso il dominio sintetico, in modo da poterle successivamente fornire alla rete PSPNet pre-addestrata.

È fondamentale sottolineare un vantaggio architettonico cruciale in questa fase del progetto: essendo modelli di unpaired image-to-image translation, CUT, UNIT e MUNIT operano in modo non supervisionato. Il loro addestramento richiede esclusivamente l'accesso alle distribuzioni marginali delle immagini (dominio reale e dominio sintetico), rendendoli completamente indipendenti dalle maschere di segmentazione. Di conseguenza, il grave label noise e le inconsistenze del ground truth documentate nella Sezione 3.4 non hanno in alcun modo inficiato l'apprendimento delle dinamiche di traduzione stilistica.

4.2.1 Traduzione con CUT

Come struttura di base, è stato impiegato un generatore di tipo ResNet a 9 blocchi e un discriminatore PatchGAN.

Per garantire la riproducibilità dell'esperimento, l'addestramento è stato configurato con i seguenti iperparametri principali:

- **Input:** Patch con risoluzione di 256×256 pixel e un batch size pari a 4.
- **Epoche e Learning Rate:** 40 epoche totali. Il learning rate (0.0002) è stato mantenuto costante per le prime 20 epoche, per poi decadere linearmente verso lo zero nelle restanti 20.
- **Bilanciamento delle Loss:** I pesi della Loss Avversaria (λ_{GAN}) e della Loss Contrastiva (λ_{NCE}) sono stati impostati entrambi a 1.0. In questo modo si è data la stessa importanza sia al fotorealismo sia al mantenimento della geometria originale.

Per analizzare la corretta convergenza di CUT eliminando il rumore dei singoli batch, i valori dei log sono stati raggruppati e mediati per ciascuna epoca.




Figura 4.3: Curve di apprendimento medie per epoca del modello CUT. A sinistra: Loss Avversaria del generatore (G_GAN). A destra: Loss Contrastiva (NCE).

L'analisi dei grafici (Figura 4.3) evidenzia un addestramento stabile e di successo:

- **Loss Avversaria (G_GAN):** Sebbene visivamente fluttuante, l'asse delle ordinate mostra che i valori oscillano in un range ristretto (tra 0.36 e 0.52). Questa stabilità conferma un buon equilibrio.

- **Loss Contrastiva (NCE):** Questa metrica è cruciale per mantenere intatte le forme originali. La curva mostra una discesa decisa nelle prime epoche, stabilizzandosi poi attorno al valore di 1.2.

La stabilità della NCE certifica che la struttura spaziale delle opere d'arte non viene alterata. Questo è un requisito fondamentale per garantire che le immagini tradotte restino perfettamente allineate con le maschere di segmentazione (ground truth) da usare nel fine-tuning.

Al termine dell'addestramento, il modello è stato testato sulle immagini reali.




Figura 4.4: Esempi di traduzione dal dominio reale a quello sintetico ottenuti tramite il modello CUT. A sinistra l'immagine originale, a destra l'output tradotto.

Come conferma l'ispezione visiva (Figura 4.4), CUT riesce ad applicare in modo convincente la colorimetria, l'illuminazione e le texture del dominio sintetico alle foto reali, mantenendo intatti i contorni degli oggetti.

4.2.2 Traduzione con UNIT

Il modello UNIT sfrutta un approccio non supervisionato basato sull'ipotesi di uno spazio latente condiviso. Utilizzando una struttura composta da due Variational Autoencoder e due Generative Adversarial Networks (GAN) accoppiate, le immagini di entrambi i domini vengono mappate in un singolo spazio rappresentativo comune. Questo garantisce che la semantica e la geometria di base vengano preservate durante la traduzione. Sta ai decodificatori specializzare l'output nello stile del dominio target.

Per garantire un confronto rigoroso, l'addestramento è stato configurato con i seguenti iperparametri principali:

- **Input e Batch Size:** Patch con risoluzione di 256×256 pixel e un batch size pari a 4, limite ragionevole delle GPU T4 (Modello base fornito da Kaggle). Dato il poco tempo a disposizione, si è reso necessario modificare i parametri di training per convergere più velocemente, sacrificando alcuni dettagli visivi, ma mantenendo comunque la coerenza e la struttura dell'immagine.
- **Bilanciamento delle Loss:** I pesi della funzione di costo sono stati calibrati per dare priorità alla coerenza semantica e alla fedeltà visiva. Il peso della Loss Avversaria (λ_{GAN}) è stato impostato a 1.0. Per forzare il mantenimento della struttura spaziale e la coerenza tra domini, sono stati assegnati pesi maggiori alla Loss di ricostruzione dell'immagine (λ_{recon_x}) e alla Loss di consistenza ciclica (λ_{cyc}), affiancate dalla Loss di ricostruzione dello spazio latente (λ_{recon_h}).
- **Iterazioni e Learning Rate:** Il learning rate è stato impostato a 0.0001 per l'ottimizzatore Adam ($\beta_1 = 0.5, \beta_2 = 0.999$), con un piano di decadimento a gradino previsto al raggiungimento delle fasi finali. L'addestramento si è protratto per oltre 36.000 iterazioni.




Figura 4.5: Curve di apprendimento del modello UNIT. A sinistra: Loss Avversaria del generatore per il dominio A. A destra: Loss di Ricostruzione dell’Immagine per il dominio A.

L’analisi dei grafici evidenzia che il modello ha raggiunto una fase di convergenza nella ricostruzione:

- **Loss Avversaria** (`loss_gen_adv_a`): La curva (a sinistra) mostra l’andamento fluttuante tipico delle GAN, oscillando in un range piuttosto stabile (tra 0.75 e 1.05) per la stragrande maggioranza del tempo. Questo indica un solido equilibrio in cui il generatore apprende a sintetizzare texture realistiche tenendo testa al discriminatore.
- **Loss di Ricostruzione dell’Immagine** (`loss_gen_recon_x_a`): Questa metrica (a destra) è cruciale per verificare il mantenimento dei dettagli e delle forme originali durante i passaggi di encoding e decoding. La curva mostra un andamento convergente relativamente veloce a partire dalle prime fasi, per poi diminuire costantemente e stabilizzarsi sotto la soglia dello 0.10 a partire dalle 25.000 iterazioni.

La stabilità della Loss di ricostruzione dell’immagine, unita all’equilibrio della loss avversaria, garantisce che la struttura spaziale delle scene non venga alterata durante il cambio di dominio. A conclusione dell’addestramento, il modello è stato applicato ai frame originali per generare la controparte sintetica.




Figura 4.6: Confronti tra dominio reale a quello sintetico (UNIT al checkpoint 35.000).

4.2.3 Traduzione con MUNIT

A differenza di architetture unimodali, MUNIT sfrutta un approccio non supervisionato che decompone le immagini in uno spazio latente del contenuto (condiviso tra i due domini per preservare la geometria) e in uno spazio latente dello stile (specifico per ciascun dominio). Come struttura di base, il generatore impiega un codificatore/decodificatore basato su blocchi residui (ResNet), mentre il discriminatore si affida a un'architettura LSGAN (*Least Squares GAN*) a tre scale.

Per garantire un confronto rigoroso, l'addestramento era stato originariamente pianificato con i seguenti iperparametri principali:

- **Input e Batch Size:** Patch con risoluzione di 256×256 pixel e un batch size pari a 4, dimensionato per ottimizzare l'occupazione in memoria della GPU.
- **Bilanciamento delle Loss:** I pesi della funzione di costo sono stati calibrati per dare priorità alla fedeltà visiva. Il peso della Loss Avversaria (λ_{GAN}) e delle Loss di ricostruzione dello Stile (λ_{recon_s}) e del Contenuto (λ_{recon_c}) sono stati impostati a 1.0. Alla ricostruzione globale dell'immagine (λ_{recon_x}) è stato invece assegnato un peso maggiore, pari a 10.0.
- **Iterazioni e Learning Rate:** Il learning rate è stato impostato a 0.0001 per l'ottimizzatore Adam ($\beta_1 = 0.5, \beta_2 = 0.999$), con un piano di decadimento a gradino previsto dopo le 40.000 iterazioni.

Tuttavia, a causa dei limiti di tempo di esecuzione imposti da Kaggle (*timeout* raggiunto alla dodicesima ora di computazione), l'addestramento si è interrotto all'iterazione 32.400. Di conseguenza, il *learning rate* si è mantenuto costante per l'intera durata effettiva del training. Per la successiva fase di traduzione e inferenza è stato dunque estratto e utilizzato l'ultimo checkpoint di pesi salvato in modo integro dall'architettura, corrispondente all'iterazione 30.000.

Per analizzare la corretta convergenza di MUNIT fino al momento dell'interruzione, i valori dei log sono stati tracciati lungo l'asse delle iterazioni effettivamente completate.




Figura 4.7: Curve di apprendimento del modello MUNIT (arrestate a 32.4k iterazioni). A sinistra: Loss Avversaria del generatore. A destra: Loss di Ricostruzione del Contenuto.

L'analisi dei grafici (Figura 4.7) evidenzia che, nonostante il termine anticipato del training, il modello aveva già raggiunto un'ottima fase di convergenza:

- **Loss Avversaria:** La curva (a sinistra) mostra l'andamento fluttuante e crescente tipico delle architetture LSGAN. L'innalzamento e la stabilizzazione raggiunta verso le ultime iterazioni indicano un equilibrio dinamico in cui il generatore apprende a sintetizzare texture realistiche tenendo testa a un discriminatore sempre più accurato.
- **Loss di Ricostruzione del Contenuto:** Questa metrica (a destra) è cruciale per certificare il mantenimento delle forme originali. La curva mostra un crollo drastico e deciso nelle primissime fasi dell'addestramento (prime 2.000 iterazioni), stabilizzandosi poi in modo pressoché piatto attorno al valore di 0.1 ben prima dell'iterazione 30.000.

La stabilità esemplare della Loss di ricostruzione del contenuto, raggiunta in tempi rapidi, garantisce che la struttura spaziale delle opere d'arte non venga alterata durante il cambio di stile. Questo ha reso il checkpoint estratto a 30.000 iterazioni del tutto idoneo alla generazione del dataset. A conclusione dell'addestramento, il modello è stato applicato ai frame originali per generare la controparte sintetica.




Figura 4.8: Esempi di traduzione dal dominio reale a quello sintetico ottenuti tramite il modello MUNIT al checkpoint 30.000. A sinistra l'immagine originale, a destra l'output tradotto.

4.3 Fine-Tuning e Valutazione sul Dominio Target

Una volta completata la fase di traduzione non supervisionata mediante i modelli generativi, si è proceduto con l'ultima fase dell'architettura proposta: il fine-tuning della rete di segmentazione semantica.

L'obiettivo di questa fase è adattare la rete PSPNet, precedentemente pre-addestrata sul solo dominio sintetico, alle caratteristiche visive del dominio reale. Le immagini reali del training set sono state tradotte verso il dominio target utilizzando separatamente i modelli CUT, UNIT e MUNIT. Successivamente, queste immagini tradotte, accompagnate dalle rispettive maschere di ground truth, sono state fornite in input alla PSPNet per aggiornare i pesi della rete.

Per garantire una transizione coerente ed evitare di distruggere le feature spaziali apprese in precedenza (*catastrophic forgetting*), il setup sperimentale ha previsto il caricamento del checkpoint finale del pre-training, applicando le seguenti configurazioni mirate:

- Il **learning rate** di base è stato ridotto a 0.0005 (esattamente un decimo rispetto alla fase iniziale). Questa scelta metodologica è cruciale nel fine-tuning, in quanto permette di aggiustare i pesi della rete in modo molto delicato per adattarli alle nuove texture.
- Per mantenere la coerenza con la baseline, sono stati conservati il **batch size** (4), le logiche di regolarizzazione (**momentum** a 0.9 e **weight decay** a 0.0001) e l'intera pipeline di *Data Augmentation* (inclusi lo scaling da 0.5 a 2.0 e le rotazioni casuali). Sotto queste condizioni, l'addestramento è stato prolungato per ulteriori 20 epoche.

4.3.1 Adattamento tramite CUT

Il primo esperimento di fine-tuning è stato condotto sfruttando le immagini tradotte dal modello CUT.




Figura 4.9: Andamento della Loss di addestramento e validazione durante il fine-tuning di PSPNet sulle immagini tradotte con CUT.

Come si evince dalla Figura 4.9, la Loss di addestramento decresce in modo stabile. Tuttavia, la Loss di validazione presenta un andamento fortemente oscillatorio e rumoroso, sintomo di una marcata difficoltà del modello nel generalizzare i pattern appresi e di una continua instabilità nell'estrazione delle feature.




Figura 4.10: Confronto delle metriche Mean Class Accuracy e Mean IoU durante il fine-tuning (epoche 30-50) con CUT.

L'analisi delle metriche di valutazione (Figura 4.10) conferma questa criticità. Sebbene si registri un lieve trend di crescita rispetto alle primissime epoche di ri-addestramento, i valori assoluti rimangono estremamente bassi. Il picco massimo registrato sul set di validazione si attesta a circa il 6.6% per la Mean IoU e al 7.5% per la Mean Class Accuracy.

A completamento dell'analisi quantitativa, si propone un confronto visivo diretto per comprendere il reale comportamento della rete sul set di test. La Figura 4.11 mette a confronto l'immagine di input (dominio reale tradotto in stile sintetico tramite CUT), la maschera di Ground Truth e la relativa predizione generata dalla rete.




Figura 4.11: Esempi di predizione: la rete classifica la quasi totalità dell'immagine come background, ignorando le opere d'arte.

L'ispezione visiva conferma in modo drastico quanto emerso dai valori di Mean IoU e le predizioni risultano inaffidabili. Infatti, la rete fallisce nel riconoscere l'integrità spaziale degli oggetti, frammentandoli in cluster di pixel privi di coerenza logica e geometrica. Il modello minimizza l'errore globale prevedendo quasi esclusivamente la macro-classe del *background*, ignorando la sagoma dell'opera d'arte.

4.3.2 Adattamento tramite UNIT

Il secondo esperimento di fine-tuning è stato condotto utilizzando il dataset tradotto attraverso l'architettura UNIT. L'obiettivo è quello di verificare l'efficacia dell'uso dello spazio latente condiviso.




Figura 4.12: Loss durante il fine-tuning (epoche 30-50) con UNIT.

Come mostrato nella Figura 4.12, la Loss di addestramento (linea blu) presenta una discesa costante, segno di un corretto apprendimento sui dati di training. Tuttavia, la Loss di validazione (linea arancione) manifesta un andamento estremamente instabile e fluttuante, conseguenza diretta delle criticità riscontrate nel dataset.




Figura 4.13: Confronto delle metriche: Class Accuracy, Mean IoU e Loss durante il fine-tuning (epoche 30-50) con UNIT.

L'instabilità dell'addestramento si riflette direttamente sulle metriche di performance (Figura 4.13). Nonostante un lieve miglioramento complessivo tra l'epoca 31 e la 50, i valori rimangono contenuti: la Mean IoU raggiunge un valore massimo del 5.7%, mentre la Mean Class Accuracy si attesta intorno al 8.7%.




Figura 4.14: Esempi di predizione: la rete non riesce nel suo goal, generando macchie di classi errate.

L'ispezione visiva conferma quanto emerso dai valori di Mean IoU e le predizioni risultano inaffidabili. Infatti, la rete fallisce nel riconoscere l'integrità spaziale degli oggetti, concentrandosi su zone centrali e generiche riconducibili a molte label. Con buona probabilità, la parziale correttezza di alcune zone di intersezione ha indotto la rete a focalizzarsi esclusivamente su specifiche aree dell'immagine, portando l'ottimizzatore a bloccarsi in minimi locali subottimali. La rete assegna etichette errate in modo disordinato su tutta l'area visiva, omettendo la macro-classe di background e perdendo qualsiasi coerenza geometrica legata allo scenario e all'opera d'arte.

4.3.3 Adattamento tramite MUNIT

Il terzo esperimento di fine-tuning è stato condotto utilizzando il dataset tradotto attraverso l'architettura multimodale MUNIT. L'obiettivo è stato quello di verificare se la capacità di MUNIT di catturare diverse varianti stilistiche potesse favorire una migliore estrazione delle feature semantiche da parte della rete PSPNet.




Figura 4.15: Andamento della Loss di addestramento e validazione durante il fine-tuning di PSPNet sulle immagini tradotte con MUNIT.

Come mostrato nella Figura 4.15, la Loss di addestramento (linea blu) presenta una discesa costante, segno di un corretto apprendimento sui dati di training. Tuttavia, la Loss di validazione (linea arancione) manifesta un andamento estremamente instabile e fluttuante. Queste forti oscillazioni indicano che il modello fatica a stabilizzare i pesi e non riesce a trovare un minimo locale robusto, evidenziando una difficoltà intrinseca nel generalizzare le feature apprese su immagini reali trasposte nel dominio sintetico.




Figura 4.16: Confronto delle metriche Mean IoU (sinistra) e Mean Class Accuracy (destra) durante il fine-tuning con MUNIT.

L'instabilità dell'addestramento si riflette direttamente sulle metriche di performance (Figura 4.16). Nonostante un lieve miglioramento complessivo tra l'epoca 31 e la 50, i valori rimangono contenuti: la Mean IoU raggiunge un

valore massimo del 7.2%, mentre la Mean Class Accuracy si attesta intorno all'8.6%.

A completamento dell'analisi quantitativa, si propone un confronto visivo diretto per comprendere il reale comportamento della rete. La Figura 4.17 mette a confronto l'immagine di input (dominio reale tradotto in stile sintetico tramite MUNIT), la maschera di Ground Truth e la relativa predizione generata dalla rete.




Figura 4.17: Esempi di predizione: la rete non riesce a identificare il background, generando una segmentazione caotica che ricopre l'intera immagine con classi errate.

L'ispezione visiva conferma in modo drastico quanto emerso dai valori di Mean IoU e le predizioni risultano inaffidabili. Infatti, la rete fallisce nel riconoscere l'integrità spaziale degli oggetti, frammentandoli in cluster di pixel privi di coerenza logica e geometrica. Il modello manifesta un grave collasso predittivo: anziché delineare le forme, ignora quasi totalmente la macro-classe del *background* per assegnare in modo disordinato un numero ridotto di etichette errate sull'intera area visiva, perdendo completamente la sagoma dell'opera d'arte e la struttura dello scenario.

4.3.4 Confronto Quantitativo

La Tabella 4.1 riassume i risultati quantitativi ottenuti sul test set, confrontando la baseline con i diversi approcci di Domain Adaptation.

Modello / Metodo di Adattamento	Mean Class Accuracy (%)	Mean IoU (%)
Baseline (Solo Sintetico - 0% Reali)	≈ 10.6	≈ 7.1
PSPNet + Fine-Tuning con CUT	7.5	6.6
PSPNet + Fine-Tuning con UNIT	8.7	5.7
PSPNet + Fine-Tuning con MUNIT	8.6	7.2

Tabella 4.1: Confronto delle prestazioni di segmentazione sul test set a seguito del fine-tuning.

I risultati quantitativi portano a una conclusione scientifica di fondamentale importanza per l'intero progetto. L'applicazione della traslazione di dominio non ha apportato un incremento prestazionale rispetto alla baseline; al contrario, le metriche evidenziano un sostanziale stallo o un lieve peggioramento.

È interessante notare come questo stallo numerico si sia manifestato visivamente in modalità di fallimento diametralmente opposte, come emerso dall'analisi qualitativa. Da un lato, il fine-tuning su immagini tradotte con CUT ha portato la rete a una drastica "under-segmentation", spingendo il modello a generalizzare l'errore prevedendo quasi esclusivamente la classe background. Dall'altro lato, i modelli basati su spazio latente condiviso (UNIT e MUNIT) hanno indotto un collasso di tipo caotico, portando la rete a ignorare il background e a frammentare l'immagine in etichette disordinate.

Come documentato nella fase esplorativa, questo esito finale non invalida l'efficacia dei modelli generativi, che hanno dimostrato eccellenti capacità di

traduzione visiva, ma evidenzia il limite invalicabile causato dalla qualità dei dati sorgente. Il massiccio *label noise* presente nel ground truth sintetico ha impedito alla rete PSPNet di apprendere una mappatura coerente tra feature visive e classi semantiche già durante la fase di pre-training. Di conseguenza, l'esperimento dimostra chiaramente che le tecniche di *Image-to-Image translation* sono strumenti altamente efficaci per mitigare il *Domain Shift fotometrico*, ma non possiedono la capacità intrinseca di compensare gravi discrepanze strutturali o rumore semantico nelle annotazioni del dataset di partenza.

Capitolo 5

Conclusioni

L'analisi dei risultati ha evidenziato scenari contrastanti tra le due fasi della pipeline.

Dal punto di vista della traduzione visiva, i modelli generativi hanno dimostrato un'eccellente capacità di mitigare il Domain Shift. Tutte le architetture testate sono riuscite ad applicare in modo convincente la colorimetria, l'illuminazione e le texture del dominio target: **CUT** ha confermato l'efficacia dell'apprendimento nel mantenere la struttura spaziale degli oggetti senza richiedere la traduzione inversa. **UNIT** e **MUNIT**, pur con la necessità di interrompere prematuramente l'addestramento a causa dei limiti computazionali, hanno dimostrato la robustezza dell'approccio basato sullo spazio latente condiviso, producendo risultati visivamente coerenti.

Nonostante il successo qualitativo della fase generativa, i risultati quantitativi della fase di segmentazione hanno evidenziato un sostanziale stallo prestazionale. Il fine-tuning di PSPNet, come era facile prevedere, non ha prodotto i miglioramenti attesi rispetto alla baseline, attestando la *Mean IoU* su valori inferiori all'8%.

Questi esiti confermano un principio fondamentale: architetture e modelli sofisticati non possono compensare difetti strutturali nei dati di partenza. L'indagine esplorativa ha infatti rivelato un massiccio *label noise* e gravi incongruenze nelle maschere di ground truth del dataset sintetico. Tali rumori hanno impedito alla rete PSPNet di estrarre e generalizzare feature semantiche affidabili già durante il pre-training.

Alla luce di quanto emerso, i futuri sviluppi di questo progetto non dovrebbero concentrarsi sulla ricerca di modelli generativi o architetture di

segmentazione più complessi, bensì sul miglioramento qualitativo del dato sorgente.

In conclusione, questo lavoro fornisce una dimostrazione empirica rigorosa dell'interdipendenza tra Image-to-Image translation e Segmentazione Semantica, riaffermando che la cura, la validazione e la pulizia del dataset costituiscono il requisito imprescindibile per il successo di qualsiasi architettura di Domain Adaptation.